역사위인특화AI

세종대왕의 지식과 말투로 대화하는 한국어 AI · 홍익대학교 종합설계(1), (2)

1. 기본 정보

- 프로젝트명: 역사위인특화AI (위인: 세종대왕)
- 구분: 홍익대학교 소프트웨어융합학과 전공과목 종합설계(1), (2) 팀 프로젝트
- 기간: 2025년 1학기, 2학기
- 과제명
  - 1학기: 감정인식 및 문맥기반 음성인터페이스를 활용한 역사인물 대화시스템
  - 2학기: 세종대왕 언어 모델 기반 온디바이스 AI
- 인원: 4명 (1·2학기 동일)

2. 한 줄 요약

역사 위인의 지식과 말투로 대화하는 한국어 AI를 세종대왕을 대상으로 개발해, 1학기에는 사료 검색 기반(RAG) 음성 대화 시스템을, 2학기에는 직접 학습하고 경량화한 온디바이스 언어모델을 구현한 프로젝트

3. 배경과 목표

배경

- AI 기반 교육 확산: 2025년 AI 디지털교과서 도입 등 AI 맞춤형 교육이 확산됨
- 할루시네이션으로 인한 역사 왜곡 위험: 언어모델이 잘못된 역사 지식을 사실처럼 말할 수 있어, 판단력이 부족한 아이들에게 역사 왜곡으로 이어질 수 있음
- 암기 위주의 역사 교육: 학생이 질문하거나 역사 인물의 감정과 생각을 체험할 기회가 없음

1학기 목표

- 음성 입력, 감정 인식, 음성 출력을 결합해 역사 인물과 대화하듯 배우는 시스템 구현
- 사료를 검색해 근거 기반으로 답하는 RAG 구조로 할루시네이션 감소

2학기 목표

- 공신력 있는 사료로 데이터셋을 구축하고 파인튜닝해 정확한 정보와 세종대왕 말투를 갖춘 모델 개발
- 양자화로 경량화해 인터넷 연결과 외부 데이터 전송 없이 기기 안에서 추론
- 메모리 사용량 2GB 이하 (갤럭시 S10 기준 RAM 6GB의 33%)

1학기 → 2학기 전환

- 1학기 시스템은 STT, LLM, TTS가 모두 외부 API에 의존해 인터넷이 없는 환경에서 사용할 수 없었음
- 1학기 발표에서 다음 과제로 제시한 "인터넷 없이 동작하는 경량 LLM"을 2학기에 구현함

4. 내 역할

- 일정 관리 및 문서 작업
- 데이터 수집·정제·전처리 (1·2학기)
- STT·TTS 모델 비교 및 적용
- 언어 모델 비교 및 학습

5. 시스템 구성

1학기: 음성 대화 시스템

- 음성 입력: Google STT로 질문을 텍스트로 변환
- 감정 인식: KoBERT로 6개 감정 분류
- 근거 검색: multilingual-e5-base 임베딩과 FAISS로 관련 사료 검색
- 답변 생성: 검색 근거와 대화 기록으로 세종대왕 말투 답변 생성
- 음성 출력: gTTS로 답변 재생

2학기: 온디바이스 언어모델

- 데이터 구축: 조선왕조실록, 한국민족문화대백과, 우리역사넷을 QA 형식으로 변환
- 베이스 모델 선정: 한국어 소형 모델 4종 비교
- LoRA 파인튜닝: 4비트로 불러와 응답 부분만 학습
- 양자화: Q4_K_M GGUF로 변환해 llama.cpp로 기기 내 추론

6. 기술 스택과 선택 이유

1학기

- LangChain, FAISS: 대화 메모리를 포함한 검색 기반 답변 체인 구성
- KoBERT: 한국어 문장 감정 분류
- Google STT, gTTS: 실시간 음성 입출력

2학기

- EXAONE 3.5 2.4B: 한국어 성능이 가장 높은 소형 모델
- Transformers, PEFT(LoRA), bitsandbytes: 4비트 양자화 상태로 적은 메모리에서 파인튜닝
- llama.cpp: 양자화 모델의 기기 내 추론

7. 기술적 결정

STT 선정

- Google STT, Whisper, VOSK를 오류율, 한국어 인식, 속도, 실시간 스트리밍 기준으로 비교함

- 정확도는 Whisper가 가장 높았지만, 10초 이내 응답 목표에 맞춰 실시간 스트리밍을 지원하는 Google STT를 선정함

TTS 선정

- gTTS, Bark, Coqui XTTS, Tacotron2, VITS 5종을 조사하고, MCD, STOI, PESQ, CER로 비교 평가함
- 문자 오류율(CER) 0.042로 답변 내용을 가장 정확하게 전달한 gTTS를 적용함

학습 데이터 형식

- 같은 사료를 원문 텍스트와 QA 형식으로 각각 학습해 비교함
- 원문 텍스트는 KMMLU 변화가 없었고, QA 1,200개 학습 시 0.407로 가장 높아 QA 형식을 채택함

베이스 모델 선정

- EXAONE 3.5 2.4B, HyperCLOVA X 1.5B, Kanana 2.1B, Qwen 2.5 1.5B를 KMMLU로 비교함
- EXAONE이 전체 정확도(0.327)와 인문·사회 영역 모두 1위로 선정함

Full Fine-tuning 대신 LoRA

- 본체 가중치를 동결하고 변화량만 저랭크 행렬로 학습해 메모리와 학습 시간을 줄임
- 응답 부분에만 loss를 계산해 질문이 아닌 답변 방식을 학습하게 함

하이퍼파라미터 선정

- Rank(1~32), Alpha(Rank의 ×1, ×2, ×4), Dropout(0.05, 0.1)만 바꾸고 나머지는 고정해 30개 조합을 실험함
- Rank는 16까지 성능이 오르다 32에서 떨어져, 데이터 규모에 맞는 용량으로 16을 선택함
- Alpha는 같은 Rank에서 클수록 좋았고, 32가 Rank 8·16·32 모두에서 상위권이었음
- Dropout은 차이가 작아 최종 후보 중 가장 성능이 좋은 0.05를 선택함
- 최종 설정: r=16, α=32, dropout=0.05

8. 문제 해결

의미가 같은 중복 질문 제거

- 문제: TF-IDF는 단어 빈도 기반이라 "누가 한글을 만들었나"와 "훈민정음을 창제한 사람은"처럼 단어가 다른 같은 질문을 구분하지 못함
- 해결: SBERT 임베딩의 코사인 유사도로 기준을 바꿔 의미 기반으로 중복 질문을 필터링함

감정 데이터 라벨 불일치

- 문제: AI Hub 감정 데이터 2종의 라벨 체계가 7개, 6개 감정으로 서로 다름
- 해결: 공통 감정으로 매핑하고, 페르소나에 맞지 않는 혐오를 제외해 6개 감정으로 통일함
- 결과: 문장-감정 데이터 179,121건 구축, 감정 분류 정확도 55% → 66%

특정 지표만 보고 모델을 고를 위험

- 문제: 지표별 1위 모델이 서로 달랐고, BLEU-4 1위 모델은 KMMLU가 0.320으로 베이스(0.327)보다 낮아 기존 지식을 잃음
- 해결: Token-F1, ROUGE-L, BLEU-4 지표별 1위 3개를 KMMLU로 재검증해, 페르소나 답변 정확도와 일반 지식이 모두 가장 높은 모델을 선정함

9. 성과

1학기

- STT, 감정 인식, RAG, TTS를 연결한 음성 대화 시스템 구현
- 감정 분류 정확도 55% → 66%, 주요 감정 F1-score 17~31% 향상

2학기 (베이스 모델 대비)

- 정답 문장과의 일치율 약 8배 향상 (Token-F1 기준)
- KMMLU 0.327 → 0.351 (7.5% 향상)
- 모델 용량 4.48GB → 1.39GB (68.9% 감소)
- 메모리 사용량 4.85GB → 1.76GB (목표 2GB 이하 달성)
- 토큰 생성 속도 150 → 195 tok/s (29.8% 향상)

10. 배운 점

- 지표로 선택하고 교차 검증하기: BLEU-4 1위 모델이 일반 지식을 잃은 것을 확인하며, 하나의 지표만 보지 않고 다른 벤치마크로 재검증하는 과정이 필요함을 배움
- 데이터는 양보다 형식이 먼저: 같은 사료라도 원문 텍스트로는 성능이 오르지 않고 QA 형식에서 효과가 있음을 확인함
- 목적에 맞는 기준으로 기술 고르기: 정확도가 가장 높은 Whisper 대신 실시간 응답 목표에 맞는 Google STT를 선택하며, 기술 선택의 기준은 서비스 목적이라는 것을 확인함
- 같은 문제를 다른 방식으로 풀기: RAG로 근거 기반 답변을, 파인튜닝으로 오프라인 동작과 말투를 얻으며 두 방식의 장단점을 이해함